AROB - Rapport Regression

Lionel ALVES VIEIRA and Thomas LU

Sorbonne Université

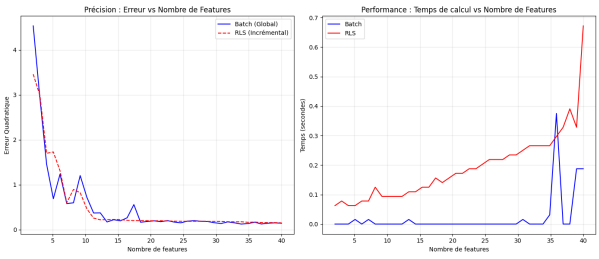
Janvier 2026

1 Protocole expérimental

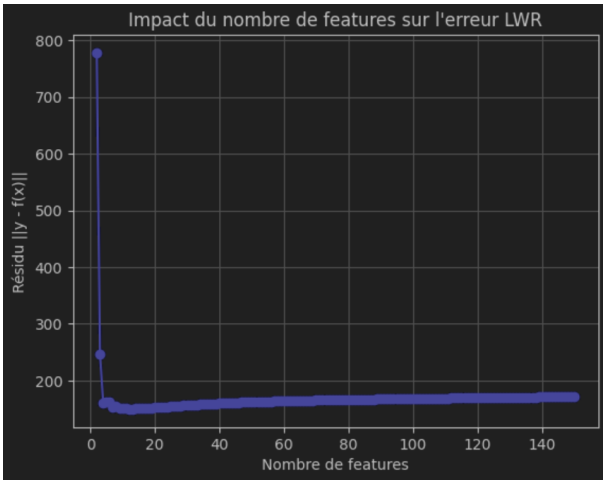
Les jeux de données sont générés en faisant varier :
— La taille du dataset (pour les études de temps) : $N \in \{100, 1000, 5000\}$,
— Le niveau de bruit gaussien : $\sigma \in \{0.01, 0.1, 0.5\}$.
Pour chaque méthode, les hyper-paramètres sont ajustés empiriquement afin d'obtenir les meilleures performances possibles :
— **RBFN** et **LWR** : nombre de features,
— **Réseaux de neurones** : taille de mini-batch.
Les métriques observées sont l'erreur quadratique moyenne (MSE) sur un jeu de test et le temps total de calcul.

2 Résultats expérimentaux

2.1 Erreur d'approximation et bruit



(a) Comparaison des erreurs résiduelles et temps d'exécution entre les méthodes Batch et Incremental RBFN.



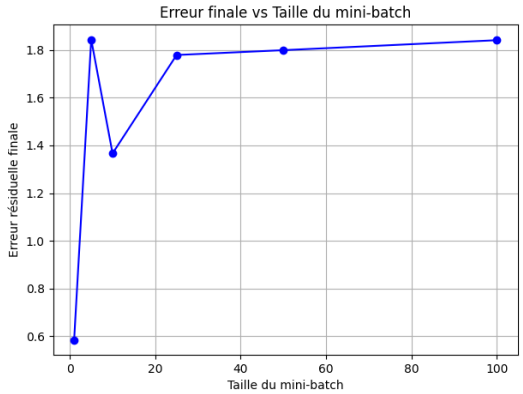
(b) Résidus en fonction du nombre de features pour LWR.

FIGURE 1 – Comparaison des performances des différentes méthodes d'apprentissage.

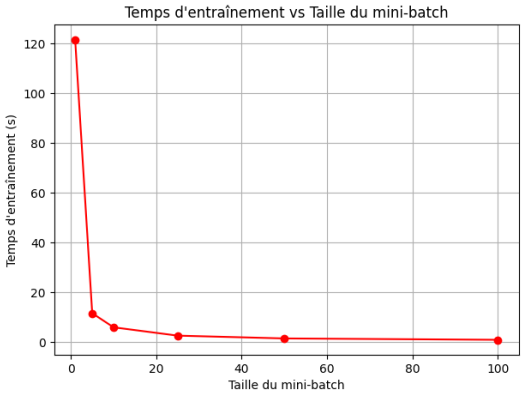
En comparant les approches *batch* et *incrémentale*, il apparaît que RLS est plus lent mais fais moins d'erreur lorsqu'il y a moins de features. Il est donc préférable d'utiliser b**atch sur des**

grosses données avec beaucoup de features et RLS sur des données avec un nombre de feature plus raisonnable.

Pour la méthode LWR, On observe que pour un petit nombre de features, l'erreur reste élevée **(sous-apprentissage)**. Cependant, en aumentant le nombre de features, l'erreur diminue rapidement. Pour un nombre très élevé de features, le modèle peut néanmoins commencer à **sur-apprendre** les données, ce qui explique la légère augmentation vers la fin de la courbe.



(a) Erreur résiduelle finale en fonction de la taille du mini-batch.



(b) Temps d'entraînement en fonction de la taille du mini-batch.

FIGURE 2 – Résultats d'entraînement en fonction de la taille du mini-batch.

On observe que l'erreur finale est minimale pour les mini-batch de petite taille et augmente lorsque la taille du mini-batch devient trop grande. Le temps d'entraînement, quant à lui, diminue rapidement avec l'augmentation de la taille du mini-batch, car le nombre d'updates est réduit. Ainsi, un compromis entre précision et temps de calcul peut être envisageable lors de la sélection de la taille du mini-batch.

2.2 Temps de calcul

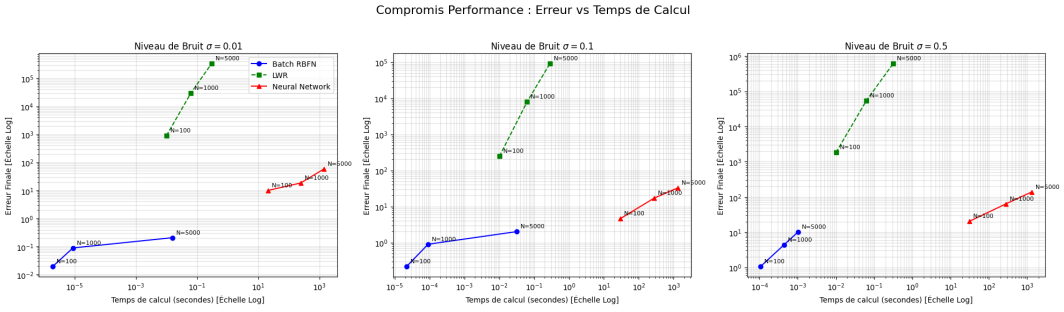


FIGURE 3 – Temps de calcul en fonction de la taille du dataset pour les trois méthodes.

La figure met en évidence le comportement des méthodes à grande échelle et assure nos remarques précédentes. La méthode **LWR** voit son erreur de calcul croître très rapidement avec la taille du dataset, mais n'est pas très sensible au bruit. Le **Batch RBFN** reste extrêmement rapide, mais sa précision se dégrade lorsque le bruit augmente. Les **réseaux de neurones** présentent sûrement le meilleur compromis pour des très grands jeux de données : bien que plus coûteux que RBFN, la croissance en temps reste maîtrisée et ils sont robustes par rapport au bruit.