AROB - Regression

Lionel ALVES VIEIRA and Thomas LU

Sorbonne Université

29 janvier 2026

1 Linear least squares

1.1 Impact of regularization

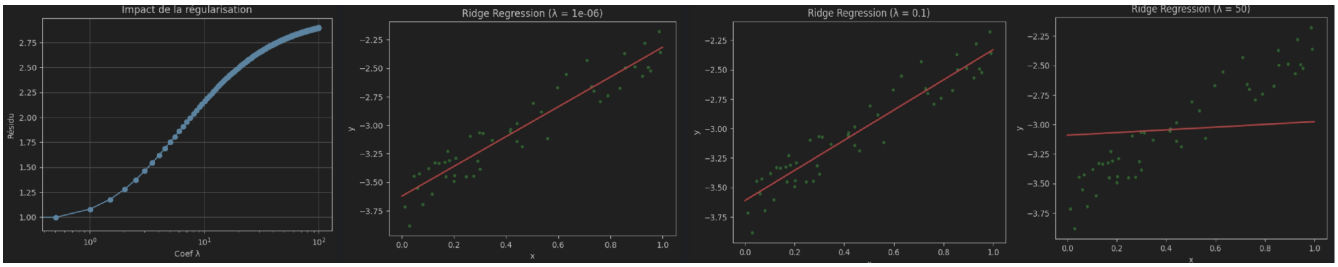


FIGURE 1 – Évolution du résidu en fonction du coefficient de régularisation λ.

On observe que pour des valeurs très faibles de λ, le résidu est minimal. Dans cette range, la régularisation a un impact quelque peu négligeable et le modèle se comporte comme une régression linéaire classique.

Cependant, lorsque λ augmente, le résidu croît de plus en plus. Cela s'explique par le fait que la régularisation pénalise la norme du vecteur des paramètres, forçant les coefficients du modèle à devenir plus petits. Le modèle devient alors plus "rigide".

Les valeurs élevées de λ entraînent un underfitting !

L'observation des modèles confirme ce comportement : plus λ est grand, plus la pente de la droite est faible. La régularisation introduit donc un compromis entre biais et variance. Elle améliore la robustesse du modèle au bruit mais perd en précision lorsque λ devient trop élevé.

2 RBFNs

2.1 Influence of the number of features

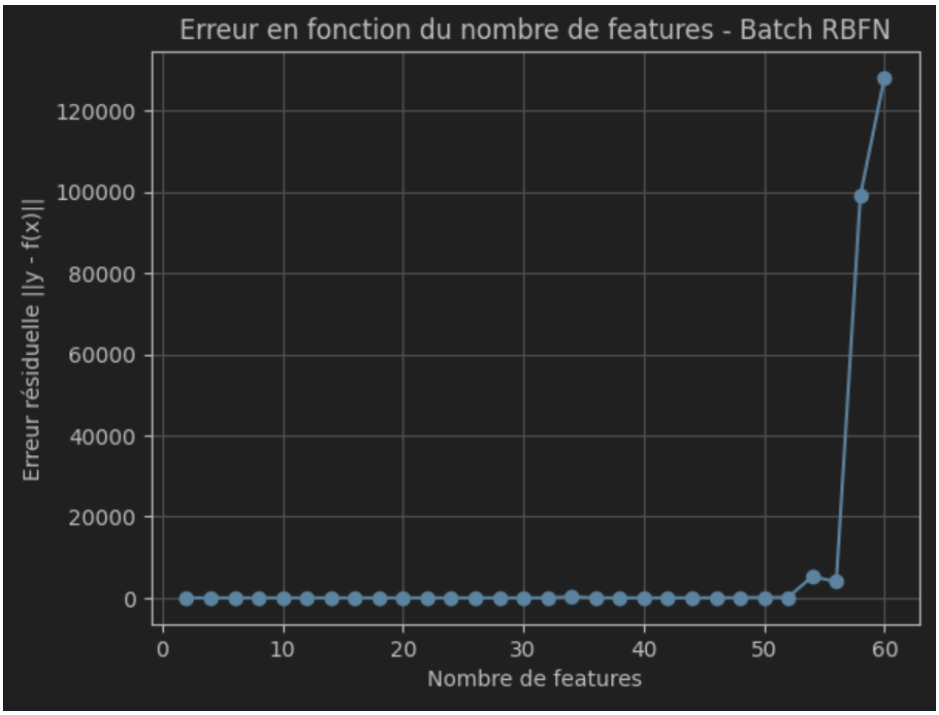


FIGURE 2 – Évolution de l'erreur résiduelle en fonction du nombre de features pour le Batch RBFN.

L'erreur est quasi nulle au début, car le modèle peut mieux approximer la fonction. Lorsque le nombre de features devient trop grand, l'erreur augmente très vite et le modèle overfit le bruit.

2.2 Incremental RBFNs - Comparaison Batch vs Incremental

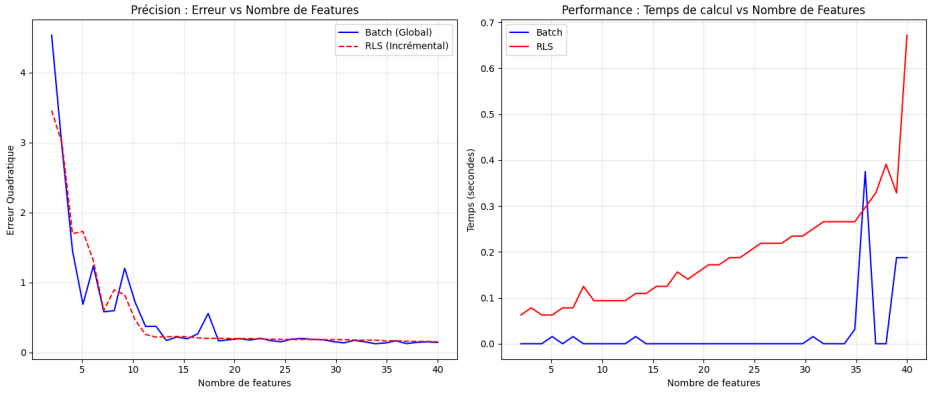


FIGURE 3 – Comparaison des erreurs résiduelles et le temps d'exécution (resp. à gauche et à droite) entre les méthodes Batch et Incremental RBFN.

En comparant les approches batch et incrémentale, il apparaît que RLS est plus lent mais fais moins d'erreur lorsqu'il y a moins de features. Il est donc préférable d'utiliser batch sur des grosses données avec beaucoup de features et RLS sur des données avec un nombre de feature plus raisonnable.

3 LWR

3.1 Impact of the number of features

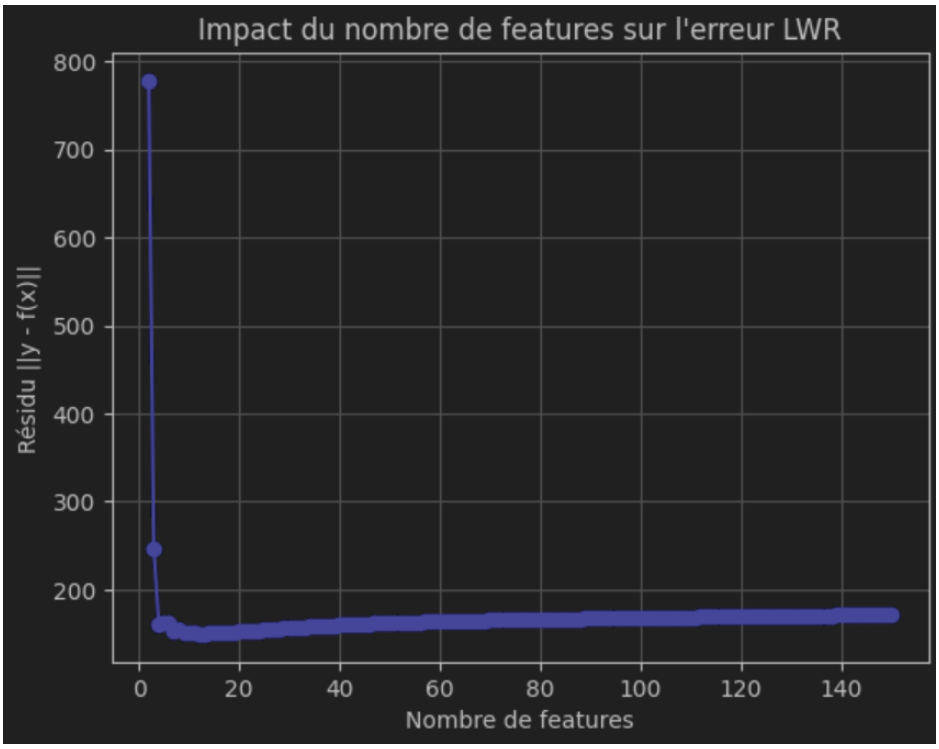


FIGURE 4 – Résidus en fonction du nombre de features pour LWR.

On observe que pour un petit nombre de features, l'erreur reste élevée (sous-apprentissage). Cependant, en aumentant le nombre de features, l'erreur diminue rapidement. Pour un nombre très élevé de features, le modèle peut néanmoins commencer à sur-apprendre les données, ce qui explique la légère augmentation vers la fin de la courbe.

4 Neural Networks

4.1 Comparisons between batch and incremental training

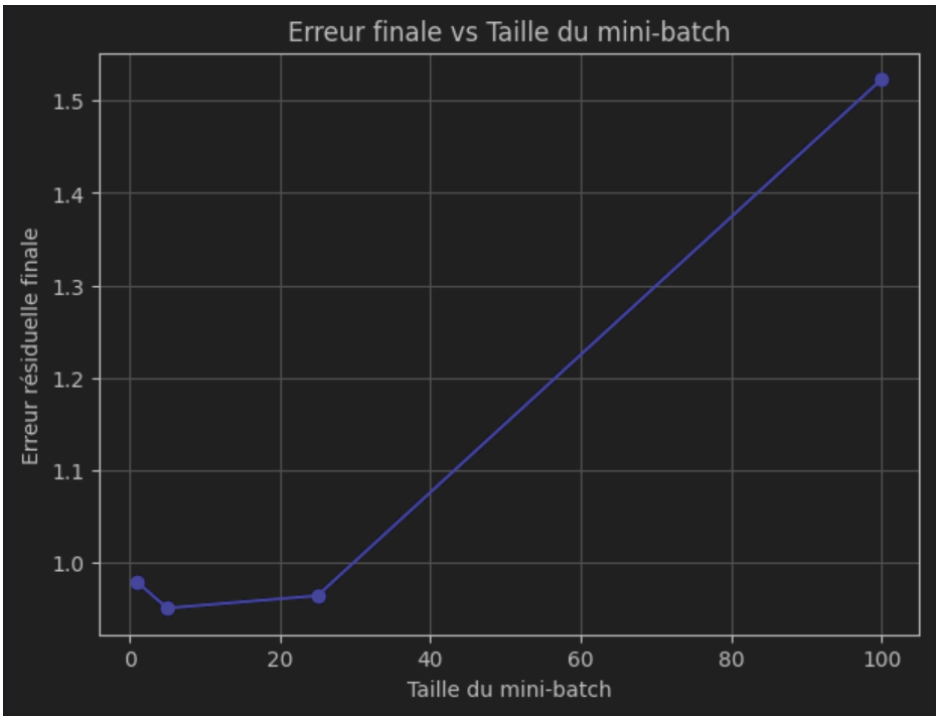


FIGURE 5 – Erreur résiduelle finale en fonction de la taille du mini-batch.

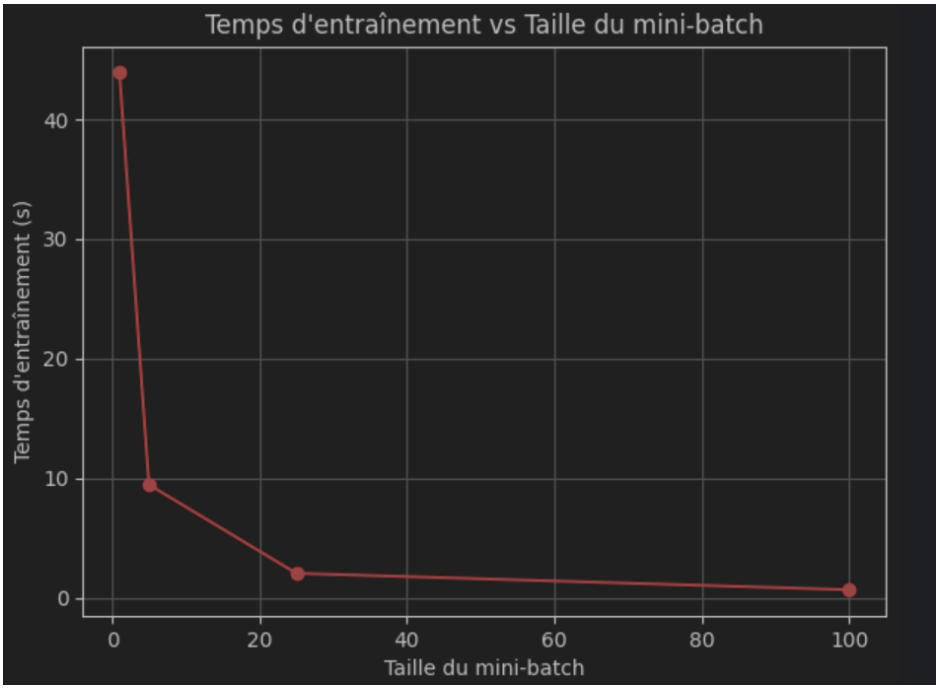


FIGURE 6 – Temps d'entraînement en fonction de la taille du mini-batch.

On observe que l'erreur finale est minimale pour les mini-batch de petite taille et augmente lorsque la taille du mini-batch devient trop grande. Le temps d'entraînement, quant à lui, diminue rapidement avec l'augmentation de la taille du mini-batch, car le nombre d'updates est réduit. Ainsi, un compromis entre précision et temps de calcul peut être envisageable lors de la sélection de la taille du mini-batch.